权威12345数据集及等级类别整理

权威12345数据集及等级类别整理

一、数据分级标准

A：三级以上分类数据。
逐条真实12345工单具有明确的三级以上分类标签，可用于三级以上分类模型训练及分类体系学习。

B：单级分类或层级尚未确认的数据。
具有真实12345工单正文及分类字段，但目前无法证明分类字段构成完整的一级—三级层级关系。

C：辅助语料。
只有公开诉求文本、信件、统计数据或其他无法作为多级分类训练标签的数据，不作为核心分类训练集。

二、已获取数据

1. 三亚市“12345”市民服务热线记录数据

等级：B；官方直接公开获取。

这是目前已经实际获取到的、规模最大的历史12345数据之一。

数据集共有 **184567条有效工单记录**，采用 GB18030 编码。北大开放研究数据平台同名数据集明确记载为三亚市“12345”市民服务热线2018年10月至2019年2月公布的18万4千余条记录。

数据主要包含工单编号、工单分类、工单来源、来电时间、来电类型、工单标题、工单内容、工单状态、处理时间、处理环节、处理单位、处理描述，以及 `extractAddress`、经纬度等字段。数据时间范围经文件核验为 **2018年10月2日至2019年2月15日**。

其**优势**是工单真实性、规模和字段完整度较高。每条记录都有真实的工单标题和工单内容，同时存在处理单位等办理信息，因此非常适合作为真实12345语料进行文本分类、工单理解、承办单位识别等研究。

但它对本赛题最大的限制也已经通过文件实际检查得到：`工单分类` 字段目前只出现诸如“建设交通类”“公安政法类”“公用事业类”“数字城管”等单级分类名称，共约12类，并**没有发现类似“住房>小区配套>下水”的三级路径**，更没有四级、五级分类字段。因此不能把它认定为三级数据。

此外，数据中没有一个明确的原始 `address` 字段，`extractAddress` 是从工单内容中抽取的位置文本，而且存在较多缺失；`处理单位` 虽然存在，但其中相当一部分是“话务01组”“12345热线后台组”等流程节点，并不全部等价于赛题中的最终承办单位。

因此，三亚数据**真实性可以确认，但不适合作为本赛题五级分类的主训练集**。它更适合作为大规模真实12345文本语料和辅助实验数据。

该数据目前在北京大学开放研究数据平台仍可查询；当前官方平台要求注册/登录后申请文件访问权限。

---

2. 上海12345诉求公开

等级：C；官方直接公开获取（爬虫）。

数据集共 **7248条记录**，时间范围为 **2020年2月14日至2026年9月20日**。

文件字段包括：
`source`、`source_record_id`、`title`、`content`、`department`、`requested_at`、`published_at`、`reply`、`source_url`、`collected_at`。

文件中的记录包含真实诉求标题、诉求正文、承办/处理部门和办理答复等信息，且每条记录都有 `source_record_id`。目前文件中的7248条记录没有发现重复ID。

但它存在一个对本赛题非常致命的问题：**没有分类字段。** 数据中虽然有 `department`，但承办部门不能等同于诉求分类，更不能由部门名称推断一级、二级、三级分类。因此不能作为三级或以上分类训练集。

因此该数据可以确认是**上海12345公开诉求语料**，但应归为D级辅助数据，主要用于补充真实政务诉求文本、分析诉求表达方式以及进行无监督/弱监督实验，不能作为当前五级分类标签数据。

---

3. 福州12345诉求公开

等级：C级；官方直接公开获取（爬虫）。

数据集共 **701条记录**，时间范围为 **2022年12月16日至2026年9月20日**。

数据字段比较完整，包括：
`title`、`content`、`category`、`property`、`address`、`area_code`、`event_source`、`requested_at`、`department`、`reply`、`reply_time` 等。

这批数据与赛题case的字段匹配程度实际上比较高：具有标题、正文、地址、时间和办理部门，同时还能区分“咨询、投诉、求助、建议”等诉求性质。

福州市人民政府门户网站目前仍公开“12345便民服务平台—诉求件查询”，公开列表明确显示**标题、诉求分类、诉求时间、状态**等字段。

但是，`category`字段目前只是诸如“道路管养”“公积金贷款”“公租房”“地铁线路”等**单级分类名称**，共有233个不同取值；`property`只是“咨询/投诉/求助/建议”等诉求性质。不能把`category`和`property`拼起来当成二级分类，更**不能自行解释成三级路径**。

不过相比上海数据，福州数据的字段结构更加贴近赛题，尤其具有**地址、时间、分类、承办单位**，所以适合作为赛题case格式的辅助验证数据。

---

4. 北京首都之窗公开信件

等级：C；官方直接公开获取（爬虫）。

数据集共 **212条公开信件**，时间范围为 **2024年9月25日至2026年9月17日**。

数据包含：
`type`、`title`、`content`、`write_date`、`reply_date`、`department`、`reply`等字段。

其来源不是北京12345逐条工单，而是**首都之窗“政民互动—近期信件选登”**。北京市人民政府官方网站目前仍公开该栏目，并持续发布公众来信及办理情况。官网显示，2026年8月首都之窗共接收公众来信21931件、办结19316件。

但它**不是严格意义上的12345工单**，也**不存在一级至五级诉求分类**字段。比较适合用作**北京市政务领域真实诉求文本辅助语料**，例如扩充领域语言表达、测试模型对北京市政务问题的理解能力。

三、尚未获取，但值得申请的数据

5. 青岛市“12345·青诉即办”数据（五级分类）

目标等级：可能A；需要数据授权或定向申请。

官方业务体系中已经实际运行“12345·青诉即办”，市政府公开材料持续披露该平台的工单受理和处置情况。2025年第二季度平台共受理公众来电来信142.97万件，数据规模较大。

此前公开资料还显示，青岛12345工单在相关智能治理场景中使用**五级分类**。因此它在理论上最接近本赛题所需要的五级分类数据。

目前没有拿到可直接下载的逐条历史工单文件，比较正规的获取路径是**青岛市公共数据运营平台的数据授权登记**。该平台目前仍正常运行，并提供“数据授权登记”“已申数据”“工作台”“身份认证”等功能。

建议申请脱敏历史12345工单，并重点要求提供三级、四级、五级分类字段。

6. 辽宁省12345政务热线高质量数据集（数据量大）

目标等级：可能A；需要数据授权或定向申请。

辽宁的数据规模非常大。国家数据局公开的高质量数据集案例明确说明，辽宁省依托12345政务热线构建省域政务热线高质量数据集，诉求数据总量**超过4亿条**，多模态数据约16T，年新增约1400万条。数据治理过程中还集成了诉求位置信息、时间序列、事件类型、处置状态、整改效果等数据。

同时，辽宁已经建立覆盖多个层级的诉求数据目录，包括48个行业领域、222项问题类型和4627项具体表现。国家数据局公开案例还明确提到数据标注、数据脱敏、访问控制和安全审计等机制。

但需要严格注意：
4亿余条是整个12345诉求数据规模，不等于4亿条全部都具有五级人工标签。

目前公开资料不足以证明每条历史工单都存在完整的三级以上分类字段。

辽宁的优势在于**规模极大、数据治理成熟、官方已经建立正式的数据调取制度**。当前更适合通过辽宁省数据和政务服务局/辽宁民心网走数据申请，而不是寻找公开下载文件。

超大规模数据源，尚未获取；建议申请脱敏历史12345数据，并明确要求逐条保留多级分类字段。

四、总体判断

三亚是最有价值的真实历史12345基础语料，但是它只有单级“工单分类”，所以不能直接作为三级/四级/五级分类训练数据。

福州的字段结构最接近赛题case，因为同时具备标题、正文、地址、时间、分类、承办部门，但当前分类字段只能确认是单级分类，因此暂时不能升级为三级数据。

上海拥有较丰富的真实诉求正文、标题、时间、部门和办理回复，但没有分类字段，因此更适合做辅助语料。

北京首都之窗公开信件真实性可以确认，但它属于政府公开信件，不是12345逐条工单，因此只能作为外围政务语料。

青岛：五级分类潜力 + 官方数据授权渠道；

辽宁：超大规模12345数据 + 官方数据调取机制。

五、结论

现有已获取数据中，尚未发现一份能够直接确认具备逐条三级、四级或五级标签的公开数据集。